

CLASE 4    6 de Marzo de 2008

Unidad 2

Redes recurrentes y autónomas

Modelo de Hopfield

Capacidad

Modelo Continuo

Ejemplos

# Redes autoasociativas


## Red de Hopfield

Regla de HEBB

Cte=  $1/N$

$$w_{ij} = \text{cte } S_i S_j$$

N: número de neuronas



Auto-asociativa

$$s_i(k+1) = \begin{cases} 1 & \text{si } \sum_{j=1}^N w_{ij} s_j(k) > \theta_i \\ s_i(k) & \text{si } \sum_{j=1}^N w_{ij} s_j(k) = \theta_i \\ -1 & \text{si } \sum_{j=1}^N w_{ij} s_j(k) < \theta_i \end{cases}$$

# ¿Cómo guardamos más de 1 patrón?

Para 2 patrones y N neuronas:

$$w_{AB} = \frac{1}{N} [S_A^1 S_B^1 + S_A^2 S_B^2]$$

peso sináptico  
entre neuronas  
A y B

Valor de la  
componente  
A del patrón 1

Valor de la  
componente  
B del patrón 1

**A B C**

**P5: +1 +1 -1**

**P7: +1 -1 -1**

Para 2 patrones:

$$w_{AB} = \frac{1}{3} [S_A^1 S_B^1 + S_A^2 S_B^2]$$

**P7: +1 +1 -1**

$$w_{AB} = 1/3 [ (+1)*(+1) + (+1)*(-1) ] = 0$$

$$w_{AC} = 1/3 [ (+1)*(-1) + (+1)*(-1) ] = -1$$

**P5: +1 -1 -1**


$$w_{BC} = 1/3 [ (+1)*(-1) + (-1)*(-1) ] = 0$$

$$[P1P2]^* [P1P2]' = \begin{pmatrix} +1 & +1 \\ +1 & -1 \\ -1 & -1 \end{pmatrix} \begin{pmatrix} +1 & +1 & -1 \\ +1 & -1 & -1 \end{pmatrix} = \begin{pmatrix} 2 & 0 & -2 \\ 0 & 2 & 0 \\ -2 & 0 & 2 \end{pmatrix}$$

$$W = \begin{pmatrix} 0 & 0 & -2/3 \\ 0 & 0 & 0 \\ -2/3 & 0 & 0 \end{pmatrix}$$

Dividimos por N y  
anulamos la  
diagonal

- 1 -1 -1 -1
- 2 -1 -1 +1
- 3 -1 +1 -1
- 4 -1 +1 +1
- 5 +1 -1 -1 ●
- 6 +1 -1 +1
- 7 +1 +1 -1 ●
- 8 +1 +1 +1




Almacenamos P5 y P7

$$w_{AB} = 1/3 [ (+1)*(+1) + (+1)*(-1) ] = 0$$

$$w_{AC} = 1/3 [ (+1)*(-1) + (+1)*(-1) ] = -2/3$$

$$w_{BC} = 1/3 [ (+1)*(-1) + (-1)*(-1) ] = 0$$

## Evolución secuencial ( $A \rightarrow B \rightarrow C$ )




**P5  $\rightarrow$  P5    Estable**

**P7  $\rightarrow$  P7    Estable**

## Evolución síncrona

Actualizamos las neuronas al mismo tiempo, es decir con un patrón de entrada constante.



**P5 → P5 Estable**

**P7 → P7 Estable**

**P3 → P4 Oscilatorio**

**P4 → P3 Oscilatorio**

**P1 → Estable espurio (no fue almacenado)**


- 1 -1 -1 -1
- 2 -1 -1 +1
- 3 -1 +1 -1
- 4 -1 +1 +1
- 5 +1 -1 -1 ●
- 6 +1 -1 +1
- 7 +1 +1 -1 ●
- 8 +1 +1 +1

**Energía**


$$E = -\frac{1}{2} \sum_{ij} w_{ij} S_i S_j$$

$$E(P1) = (-1) \times (-2/3) \times (-1) \times (-1) = +2/3$$

$$E(P5) = (-1) \times (-2/3) \times (+1) \times (-1) = -2/3$$







Para  $p$  patrones y  $N$  neuronas

$$w_{ij} = \frac{1}{N} \sum_p S_i^p S_j^p$$

Suma sobre  
patrones

Peso sináptico entre neuronas  $i$  y  $j$

$$\begin{pmatrix} P & P & P & P \\ a & a & a & a \\ t & t & t & t \\ r & r & r & r \\ ó & ó & ó & ó \\ n & n & n & n \\ 1 & 2 & 3 & 4 \end{pmatrix}$$

$$\begin{pmatrix} \text{Patrón 1} \\ \text{Patrón 2} \\ \text{Patrón 3} \\ \text{Patrón 4} \end{pmatrix}$$


podemos calcular  
la matriz de pesos  
usando el  
producto entre  
matrices

# Diferencias entre actualización síncrona y actualización secuencial

Hay diferencias entre la dinámica síncrona y secuencial.

Ambas convergen y son estables pero en el caso síncrono aparecen oscilaciones entre estados.

Podemos interpretar el comportamiento mirando la superficie de energía



# Capacidad de almacenamiento

- ¿Qué ocurre con un patrón No Memorizado?
- Memorizamos un único patrón y analizamos que sucede con otro patrón que difiere en  $n$  entradas del patrón memorizado.

$$r_i = \begin{cases} -s_i & i = 1, 2, \dots, n \\ s_i & i = n + 1, n + 2, \dots, N \end{cases}$$

$$\begin{aligned} S_i(1) &= \operatorname{sgn} \left[ \sum_{j=1}^N w_{ij} S_j(0) \right] = \operatorname{sgn} \left[ \sum_{j=1}^N w_{ij} r_j \right] = \operatorname{sgn} \left[ \sum_{j=1}^n w_{ij} (-s_j) + \sum_{j=n+1}^N w_{ij} s_j \right] \\ &= \operatorname{sgn} \left[ \sum_{j=1}^n \left( \frac{1}{N} s_i s_j \right) (-s_j) + \sum_{j=n+1}^N \left( \frac{1}{N} s_i s_j \right) s_j \right] = \operatorname{sgn} \left[ \frac{-1}{N} \sum_{j=1}^n s_i + \frac{1}{N} \sum_{j=n+1}^N s_i \right] \\ &= \operatorname{sgn} \left[ \frac{-n}{N} s_i + \frac{N-n}{N} s_i \right] = \operatorname{sgn} \left[ \left( 1 - \frac{2n}{N} \right) s_i \right] \end{aligned}$$

$$r_i = \begin{cases} -s_i & i = 1, 2, \dots, n \\ s_i & i = n+1, n+2, \dots, N \end{cases}$$

$$\begin{aligned} S_i(1) &= \operatorname{sgn} \left[ \sum_{j=1}^N w_{ij} S_j(0) \right] = \operatorname{sgn} \left[ \sum_{j=1}^N w_{ij} r_j \right] = \operatorname{sgn} \left[ \sum_{j=1}^n w_{ij} (-s_j) + \sum_{j=n+1}^N w_{ij} s_j \right] \\ &= \operatorname{sgn} \left[ \sum_{j=1}^n \left( \frac{1}{N} s_i s_j \right) (-s_j) + \sum_{j=n+1}^N \left( \frac{1}{N} s_i s_j \right) s_j \right] = \operatorname{sgn} \left[ \frac{-1}{N} \sum_{j=1}^n s_i + \frac{1}{N} \sum_{j=n+1}^N s_i \right] \\ &= \operatorname{sgn} \left[ \frac{-n}{N} s_i + \frac{N-n}{N} s_i \right] = \operatorname{sgn} \left[ \left( 1 - \frac{2n}{N} \right) s_i \right] \end{aligned}$$

$$S_i(1) = \begin{cases} -s_i & \text{si } n > N/2 \\ s_i & \text{si } n \leq N/2 \end{cases}$$

Recuperaremos el patrón guardado si:

$$n \leq \frac{N}{2}$$

- ¿Funciona igual de bien cuando queremos memorizar varios patrones?

Estado inicial:

$$h_i^p = \sum_j w_{ij} S_j^p = S_i^p + \frac{1}{N} \sum_{q \neq p} S_i^q \sum_j S_j^q S_j^p =$$

$$h_i^p = S_i^p + ruido$$

Para patrones no correlacionados y  
con probabilidad 50% de +1's y -1's

$$h_i^p = S_i^p + \mathcal{O}\left(\sqrt{\left(\frac{p-1}{N}\right)}\right)$$

De donde si  $p \ll N$  todos los patrones son estables

- ¿ Es capaz la red de recuperar un patrón distorsionado (con ruido) ? Modifiquemos en un patrón  $n$  componentes

$$h_i^p = (1 - \frac{2n}{N}) S_i^p + \mathcal{O}(\sqrt{\frac{p-1}{N}})$$

$n$ : componentes modificadas

$N$ : número de componentes = número de neuronas


$p$ : patrones almacenados

De donde si  $p \ll N$  y  $n \ll M$  los patrones son estables y podremos recuperarlos aún si los modificamos con cierto nivel de ruido

# Capacidad de almacenamiento de la red de Hopfield

- Considerando patrones almacenados ( $p$ ) y total de neuronas ( $N$ )

$$C = \frac{p}{N} = 0.138$$



Porcentaje de errores en la red de Hopfield en función del nivel de almacenamiento (Patrones aleatorios, 50% de 1 , 50% de -1)





# Capacidad

- Si los patrones se escogen ortogonales, el estado de la neurona se mantiene. Por tanto, la red se estabiliza y nos devuelve el patrón correcto.
- Otra posibilidad es utilizar un número de neuronas ( $N$ ) muy elevado en comparación con el número de patrones que queremos memorizar ( $p$ ). Esto no nos asegura resultados excentos de error, pero sí “aceptables”.
- Utilizar otras reglas de aprendizaje, como la regla de la pseudoinversa.


# El modelo de Hopfield continuo

- Estado discreto  $s_i \in \{-1, 1\}$
- Tiempo (actualización) discreto,  $k = 1, 2, 3, \dots$



- Estado **continuo**  $x_i \in [-1, 1]$
- Tiempo (actualización) **continuo**,  $t \in (0, \infty]$

$$f(u) = \frac{e^{\beta u} - e^{-\beta u}}{e^{\beta u} + e^{-\beta u}}$$



# El modelo de Hopfield continuo

## Dinámica de la computación

$$\frac{dx_i(t)}{dt} = \begin{cases} 0 & \text{si } x_i(t) = 1 \text{ y } f\left(\sum_{j=1}^N w_{ij}x_j(t) - \theta_i\right) > 0 \\ 0 & \text{si } x_i(t) = -1 \text{ y } f\left(\sum_{j=1}^N w_{ij}x_j(t) - \theta_i\right) < 0 \\ \eta f\left(\sum_{j=1}^N w_{ij}x_j(t) - \theta_i\right) & \text{si } x_i(t) \in (-1,1) \end{cases}$$

## Función de energía computacional

$$E(t) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N w_{ij}x_i(t)x_j(t) + \sum_{i=1}^N \theta_i x_i(t)$$

# Diferencias entre el modelo de Hopfield discreto y continuo.

Cualitativamente hay pocas diferencias.

Ambos modelos convergen a mínimos y son estables.

Puede definirse la función energía en ambos casos.

El modelo continuo es útil para posibles implementaciones en circuitos digitales y es biológicamente más realista.

El modelo continuo tiene una superficie de energía más suave, con menos estados espurios y por lo tanto la convergencia es mejor.

# Resumen Red de Hopfield

Modelo de red recurrente para memoria asociativa

Podemos almacenar patrones y recuperarlos usando la regla de Hebb

La definición de una función energía es útil para demostrar la convergencia de la dinámica

La capacidad de almacenamiento no es demasiado elevada ( $p=0.138$  N) pero puede mejorarse (usando otras reglas, patrones ortogonales)

Existen estados espurios no deseados.

# Calendario

Semana próxima: Semana Cultural: posible cambio de horario 18:30 → 20:30

Después de Semana Santa comienzan los laboratorios.

Ejercicio para entregar próxima semana

Prueba de control: 1era semana de Abril